

Universidad Nacional Autónoma de México
Facultad de Ingeniería
Minería de Datos

Práctica 3.6

Redes Neuronales Convolucionales (CNN)

Reconocimiento de Emociones Faciales con FER-2013

Equipo 10
Prof. Jose Roberto Olvera Lopez

Mayo 2026

Índice

1. Propósito de la Práctica	2
1.1. Contexto: Estudio Original	2
1.2. Caso de Negocio	2
1.3. Objetivo Técnico	3
2. Pasos Realizados y Parámetros Seleccionados	3
2.1. Dataset: FER-2013	3
2.2. Preprocesamiento y Aumento de Datos	3
2.3. Arquitectura de la CNN	4
2.4. Compilación y Entrenamiento	4
2.4.1. Callbacks de Entrenamiento	5
3. Resultados Obtenidos	5
3.1. Métricas Globales	5
3.2. Reporte de Clasificación por Clase	6
3.3. Curvas de Entrenamiento	6
3.4. Matriz de Confusión	7
4. Conclusiones	7
4.1. Rendimiento por clase	7
4.2. Emociones más difíciles	7
4.3. Relevancia para el caso de negocio	7
4.4. Mejoras propuestas	8

1. Propósito de la Práctica

1.1. Contexto: Estudio Original

En 2020, Sturm et al. (UCSF) publicaron un ensayo clínico aleatorizado con 60 adultos mayores (60–90 años) en el que evaluaron si caminatas breves diseñadas para cultivar **asombro** (*awe*) podían mejorar el bienestar emocional [1]. Durante ocho semanas, los participantes tomaban tres *selfies* por caminata —1,184 fotos en total— y respondían encuestas de estado emocional al terminar cada sesión.

Para analizar los cambios conductuales en las fotografías, los autores emplearon MATLAB Image Processing Toolbox: binarizaron cada imagen en píxeles “yo” vs. “fondo” y calcularon el *self-size* —qué proporción del encuadre ocupa la persona— como indicador indirecto de auto-enfoque. Adicionalmente, codificaron **manualmente** la intensidad de sonrisa en cada foto. Los resultados mostraron que los participantes del grupo *awe* progresivamente cedieron más espacio al entorno y sonrieron con mayor intensidad semana a semana.

1.2. Caso de Negocio

El protocolo del estudio original presenta dos limitaciones prácticas:

1. **Escalabilidad:** la codificación manual de sonrisas es costosa y subjetiva; MATLAB requiere umbralización artesanal por sesión.
2. **Riqueza emocional:** el *self-size* captura comportamiento de encuadre, no emoción directamente; la codificación manual solo distingue intensidad de sonrisa, sin mapear el espectro emocional completo.

Una extensión natural del estudio consistiría en **reemplazar ambas métricas por un clasificador automático de expresiones faciales**. Este clasificador permitiría:

- Rastrear trayectorias emocionales longitudinales (semana 1 → semana 8) de forma automática.
- Comparar la distribución de emociones entre el grupo *awe* y el grupo control.
- Probar la hipótesis de que el grupo *awe* exhibirá un incremento progresivo en clasificaciones **happy** y una reducción en **neutral/sad**.
- Escalar el protocolo a estudios con mayor número de participantes sin costo analítico proporcional.

Las 1,184 selfies recopiladas en el estudio original no están disponibles públicamente —los participantes son adultos mayores y los datos permanecen bajo resguardo por consideraciones éticas y de privacidad—. Por ello, este trabajo entrena el clasificador sobre el

dataset público **FER-2013** como *proxy*. FER-2013 ofrece la misma tarea de clasificación (7 emociones, imágenes de rostros en condiciones variables) y permite validar la arquitectura antes de su eventual aplicación sobre el corpus del estudio.

1.3. Objetivo Técnico

Entrenar una Red Neuronal Convolutiva (CNN) capaz de clasificar imágenes de rostros humanos en **7 categorías de emoción**: *angry*, *disgust*, *fear*, *happy*, *neutral*, *sad* y *surprise*.

2. Pasos Realizados y Parámetros Seleccionados

2.1. Dataset: FER-2013

Cuadro 1: Características del dataset FER-2013

Atributo	Valor
Fuente	Kaggle — msambare/fer2013
Total de imágenes	$\approx 35,000$
Conjunto de entrenamiento	28,709 imágenes
Conjunto de prueba	7,178 imágenes
Resolución	48×48 px, escala de grises
Clases	7 (angry, disgust, fear, happy, neutral, sad, surprise)

2.2. Preprocesamiento y Aumento de Datos

Las imágenes se normalizaron dividiéndolas entre 255 para escalar los píxeles al rango $[0, 1]$. Para el conjunto de entrenamiento se aplicó aumento de datos con el objetivo de mejorar la generalización del modelo y reducir el sobreajuste:

```

1 train_datagen = ImageDataGenerator(
2     rescale=1./255,
3     rotation_range=10,
4     width_shift_range=0.1,
5     height_shift_range=0.1,
6     horizontal_flip=True,
7     zoom_range=0.1
8 )
9 test_datagen = ImageDataGenerator(rescale=1./255)

```

El conjunto de prueba solo recibe normalización, sin transformaciones aleatorias, para garantizar una evaluación reproducible.

2.3. Arquitectura de la CNN

La red se compone de tres bloques convolucionales seguidos de capas de clasificación:

Cuadro 2: Arquitectura de la CNN

Capa	Configuración	Parámetros
Conv2D (bloque 1)	32 filtros, kernel 3×3, ReLU	320
BatchNormalization	—	128
MaxPooling2D	pool 2×2	0
Conv2D (bloque 2)	64 filtros, kernel 3×3, ReLU	18,496
BatchNormalization	—	256
MaxPooling2D	pool 2×2	0
Conv2D (bloque 3)	128 filtros, kernel 3×3, ReLU	73,856
BatchNormalization	—	512
MaxPooling2D	pool 2×2	0
Flatten	—	0
Dense	256 unidades, ReLU	524,544
Dropout	tasa = 0.5	0
Dense (salida)	7 unidades, Softmax	1,799
Total parámetros entrenables		619,463

2.4. Compilación y Entrenamiento

```

1 model.compile(
2     optimizer='adam',
3     loss='categorical_crossentropy',
4     metrics=['accuracy']
5 )
6 model.fit(train_generator, epochs=50,
7         validation_data=test_generator, callbacks=callbacks)

```

- **Optimizador:** Adam — adapta la tasa de aprendizaje por parámetro, acelerando la convergencia en clasificación de imágenes.
- **Función de pérdida:** `categorical_crossentropy` — apropiada para clasificación multiclase con etiquetas *one-hot encoded*.

- **Épocas máximas:** 50 (controladas por *callbacks*).
- **Tamaño de lote:** 64.

2.4.1. Callbacks de Entrenamiento

Se utilizaron tres *callbacks* para mejorar la calidad del entrenamiento:

Cuadro 3: Callbacks configurados

Callback	Parámetros clave	Función
ModelCheckpoint	monitor='val_accuracy', save_best_only=True	Guarda <code>best_model.keras</code> cada vez que <code>val_accuracy</code> mejora.
ReduceLROnPlateau	factor=0.5, patience=3, min_lr=1e-6	Reduce el learning rate a la mitad si <code>val_loss</code> no mejora en 3 épocas consecutivas.
EarlyStopping	patience=8, restore_best_weights=True	Detiene el entrenamiento si <code>val_loss</code> no mejora en 8 épocas; restaura los mejores pesos.

3. Resultados Obtenidos

3.1. Métricas Globales

El modelo alcanzó una **precisión global de 63.03 %** en el conjunto de prueba (pérdida: 0.9993).

3.2. Reporte de Clasificación por Clase

Cuadro 4: Métricas de clasificación por emoción

Emoción	Precisión	Recall	F1-Score	Soporte
Angry	0.52	0.58	0.55	958
Disgust	0.80	0.18	0.29	111
Fear	0.49	0.32	0.38	1024
Happy	0.85	0.86	0.85	1774
Neutral	0.56	0.69	0.62	1233
Sad	0.49	0.50	0.50	1247
Surprise	0.76	0.77	0.76	831
Macro avg	0.64	0.55	0.56	7178
Weighted avg	0.63	0.63	0.62	7178

3.3. Curvas de Entrenamiento




Figura 1: Accuracy y Loss por época durante el entrenamiento

3.4. Matriz de Confusión




Figura 2: Matriz de confusión sobre el conjunto de prueba

4. Conclusiones

4.1. Rendimiento por clase

El modelo alcanzó una precisión global de 63 % sobre FER-2013, con desempeño muy dispar entre clases. *Happy* obtuvo el mejor resultado ($F1 = 0.85$) gracias a sus rasgos faciales altamente distintivos. *Surprise* también mostró buen desempeño ($F1 = 0.76$). En contraste, *disgust* obtuvo el $F1$ más bajo (0.29) debido a un severo desbalance de clases: solo 111 muestras de prueba frente a 1,774 de *happy*.

4.2. Emociones más difíciles

Las emociones *fear* y *sad* presentaron los menores rendimientos ($F1 = 0.38$ y 0.50 , respectivamente) por dos razones complementarias: comparten microexpresiones faciales similares —comisuras hacia abajo, tensión en cejas—, y el desbalance de clases impide al modelo aprender representaciones suficientemente discriminativas para *disgust*.

4.3. Relevancia para el caso de negocio

Desde la perspectiva de Sturm et al., el resultado más importante es que *happy* —la emoción central del protocolo de *awe walks*— alcanza $F1 = 0.85$, validando la utilidad del

clasificador para rastrear trayectorias emocionales longitudinales. El buen desempeño en *surprise* ($F1 = 0.76$) también es relevante, ya que el asombro se manifiesta frecuentemente como una combinación de felicidad y sorpresa. El bajo rendimiento en *disgust* y *fear* no representa un obstáculo crítico, pues esas emociones no son las hipótesis de interés del estudio.

4.4. Mejoras propuestas

1. **Balanceo de clases:** aplicar *oversampling* (SMOTE o aumento de datos agresivo) sobre las clases minoritarias, particularmente *disgust*.
2. **Transfer learning:** reemplazar la arquitectura desde cero por un modelo pre-entrenado (VGG16, EfficientNetB0) con *fine-tuning*. En FER-2013, estas arquitecturas alcanzan 70–75 % de accuracy.
3. **Adaptación al dominio:** el corpus del estudio consiste en selfies de adultos mayores en exteriores, dominio diferente al de FER-2013. Un ciclo de *domain adaptation* o fine-tuning sobre una pequeña muestra anotada mejoraría significativamente el desempeño en producción.
4. **Umbral de confianza por clase:** en producción, usar umbrales diferenciados para rechazar predicciones de baja confianza en clases como *fear* y *disgust*.

Referencias

- [1] Sturm, V. E., Datta, S., Roy, A. R. K., Sible, I. J., Kosik, E. L., Veziris, C. R., Chow, T. E., Morris, N. A., Neuhaus, J., Kramer, J. H., Miller, B. L., Holley, S. R., & Keltner, D. (2022). *Big smile, small self: Awe walks promote prosocial positive emotions in older adults*. *Emotion*, 22(5), 1044–1058. <https://doi.org/10.1037/emo0000876>
- [2] Goodfellow, I. J., Erhan, D., Carrier, P. L., Courville, A., Mirza, M., Hamner, B., Cukierski, W., Tang, Y., Thaler, D., Lee, D.-H., Zhou, Y., Ramaiah, C., Feng, F., Li, R., Wang, X., Athanasakis, D., Shave-Taylor, J., Milakov, M., Park, J., . . . Bengio, Y. (2013). *Challenges in Representation Learning: A Report on Three Machine Learning Contests*. arXiv:1307.0414.
- [3] Sambare, M. (2020). *FER-2013* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/msambare/fer2013>
- [4] LeCun, Y., Boser, B., Denker, J. S., Henderson, D., Howard, R. E., Hubbard, W., & Jackel, L. D. (1989). *Backpropagation applied to handwritten zip code recognition*. *Neural Computation*, 1(4), 541–551.

- [5] Abadi, M., et al. (2015). *TensorFlow: Large-scale machine learning on heterogeneous systems*. <https://www.tensorflow.org>